神经网络是在同一起跑线上吗？论初始值如何影响学习表征

吴秉阳	韩汶辰	文泓宇	祁晟
1800013077	1800013093	1800013069	1800013046

Abstract

目前深度学习在许多领域都取得了巨大的成功，人们普遍认为神经网络能够学习到对知识的好的表示，但这样的相信并没有得到理论和实验的支撑。在这次工作中，我们通过大量的实验测试，在揭开神经网络表示的神秘面纱路上前进了一小步。具体来说，我们对于多个有相同结构、同样的初始化方法、同样的训练方法但初始权值不同的网络，研究它们在不同的任务下表现有何异同。我们将神经网络看成黑盒，使用了迁移学习和对抗攻击两种下游任务，分别从宏观和微观的角度对这些网络的结构有了一些瞰视。它们在所有任务上总体表现得十分类似，对于迁移任务表现出了相似的泛化性，但在对抗攻击下我们能够发现它们在局部上的巨大差异。

1 引言

人们普遍认为深度神经网络成功的主要原因是，它们能通过训练学到好的表示。[8] 我们给神经网络赋予直观的名字：卷积、池化、记忆、过滤等，并相信它们就是如此工作，即使并没有强有力的证据来说明这一点。对于神经网络的层次结构的释义，我们依然知之甚少。在这项工作中，我们通过大量实验手段，从多个角度衡量神经网络的表示性，在揭开其神秘面纱的路上前进了一小步。具体来说，我们研究一个子问题：对于多个有相同结构、同样的初始化方法、同样的训练方法但初始权值不同的网络，它们有多么相似或者多么不相似？或者说，初始权值的不同是否会让神经网络从训练数据中提取出不同的信息，学习到不太相似、却同样有效的表示？

神经网络的结构非常复杂，深层次的神经网络，其复杂程度呈几何式上升。大量的权重值和激活函数使得神经网络成为一个高度复合体，想要直接从权重矩阵入手，通过梳理其结构来研究神经网络的表示性十分困难。因此，我们转向不同的下游任务，并希望能在不同的角度下，探索其表征的异同。

34th Conference on Neural Information Processing Systems (NeurIPS 2020), Vancouver, Canada.

我们的最初想法来自一个二分类器。不妨将所有数据集看作擢选自高维空间的样本，而分类器看作一个高维图形。我们意识到，不论初始化如何，分类器们能在原数据集上能够做到高准确率，这意味着在高维空间的某种超平面上，分类器们的投影都是相似的，都包住了一些数据而避开了另一些数据。这意味着若想要研究其不同，我们仅仅希望从现有的数据出发是不够的。因此，第一个想法是，我们检查它们是否通过很少的泛化，就能在另一个超平面上获得相似的投影，而这与迁移学习的理念，即泛化到另一个数据集上，不谋而合；另一个想法是，在已有数据的某个较小邻域内，不同的分类器是否会表现出较大的差异，若是，则说明在某些位置它们在超平面上的边界并不相同。这一想法将通过对抗学习来完成。

具体而言，我们研究一个经典图像分类任务。我们在同样的数据集上训练五个初始化权值不同的 ResNet [5]，并尝试找到它们的某种差异性。

在迁移学习中，不难想象，若不同的神经网络确实学到了相同的特征，那若尝试将它们泛化到其他数据集上，它们也会表现出相似。具体而言，神经网络会尝试利用在原数据集上学到的特征，应用到新数据集上进行分类，即展示出相同的泛化性。在下文我们将展示它们的运行，情况显示它们展现出了非常类似、但略有区别的泛化能力。

在对抗攻击中, 我们知道, 仅仅对输入增加一个很小的扰动就能对神经网络的分类产生巨大的影响, 但我们的问题是, 针对一个神经网络的对抗样本对另一个神经网络也起作用吗? 如果两个神经网络是几乎等价的, 那么对抗样本便具有良好的迁移性, 即对抗样本也能欺骗另一个未被针对的网络, 如果两个网络在对抗样本的差距较大, 则能说明二者是**局部不相似的**.

而更进一步地, 我们还希望探究两个神经网络决策边界的相似性, 这是反映神经网络相似度的本质. 为衡量高维空间凸性的相似度, 我们转而使用到决策边界的距离衡量决策边界的相似度, 如果取对抗方向, 则衡量的是局部相似度, 如果取随机方向, 则衡量的是决策边界的全局相似度.

作为总结，我们在这次课程项目中阅读了许多领域的大量文献，实现了许多代码，对神经网络的认知更进一步。我们的主要工作如下：

- 我们提出了通过迁移学习的泛化性来衡量神经网络的相似性
- 我们通过衡量对抗攻击的可迁移性衡量神经网络相似性, 并在此基础上通过定义到边界的距离比相似度进一步研究两个网络决策边界的相似性. 我们还给出了决策边界的可视化结果.
- 实验结果表明，不同初始化权值的神经网络最终在整体上展现了一致性，但在局部仍体现出可检测的较大差异.

2 相关工作

我们参考了许多相关论文，并在不同领域的工作中获得了启发。具体来说，我们着眼于有关迁移学习，对抗攻击，神经网络相似性等方面的文献。

2.1 迁移学习

迁移学习是机器学习的一个子领域。它专注于存储已有问题的解决模型，并将其利用在其他不同但相关问题上。在许多机器学习和数据挖掘算法中，一个主要的假设是训练和未来的数据必须是在相同的特征空间中具有相同的分布。然而，在许多实际应用程序中，这种假设可能不成立。例如，我们有时在一个感兴趣的领域有一个分类任务，但在另一个领域只有足够的训练数据，其中后一个数据可能位于不同的特征空间或遵循不同的数据分布。在这种情况下, 如果成功地进行知识转移，就可以避免昂贵的数据标记，从而大大提高学习的性能。[14]

自然界的图片都具有某种程度的相似性，许多纹理特征、形状特征都能在不同类别的图片上找到。譬如，在神经网络学习辨析汽车的知识时，它也会学到辨析卡车的知识；而辨析汽车的知识，也能以某种程度运用在辨析服装上。

这一领域被认为在 1993 年 Lorien Pratt 的工作 [15] 提出。在这篇工作中，他谈到从为相关源任务训练的网络中获得的权值，可以加速对目标问题的学习。为这一目的，他提出了基于可辨识性地 DBT (Discriminability-Based Transfer) 算法，该算法使用一种信息测度来估计目标网络中由源权值定义的超平面的效用，并相应地转移权值大小。

2007 年，戴文渊在他的工作 [2] 中提出了新的 TrAdaBoost 框架，并指出学习一个精确的模型只用少量的新数据和大量旧的数据就已经足够, 即使新数据不足以单独训练一个模型。在深度学习领域，学者们建立按照不同的概率分布在不同的领域进行泛化，并在在计算机视觉 (Saenko et al., 2010, ; Gopalan et al., 2011; Gong et al., 2012; Hoffman et al.2014) 、自然语言处理 (Collobert et al., 2011; Glorot et al., 2011) [11] 等领域都有迁移学习广泛的应用。

2.2 对抗攻击

对抗攻击是伴随深度学习产生的一个新兴领域, 它表明了神经网络的鲁棒性较弱, 它表明, 我们只需要给输入加入一个很小的噪声, 该噪声人眼几乎无法察觉, 就能改变神经网络的决策. 这也可以表明, 或者说神经网络对应的函数是不平坦的, 它在某些局部的波动很剧烈, 具有局部不一致性.

GoodFellow et al. [4] 首次提出使用 FGSM(Fast Gradient Sign Method) 来生成对抗样本, 并且做到了在使用较小模长的扰动时, 以 90% 以上的概率欺骗神经网络. 而 [13] 表明, 存在某种扰动向量 (universal perturbation), 使得其作用于所有的图片, 都会以以较高的概率欺骗神经网络. Liu et al. [10] 表明, 对抗样本一定程度上具有可迁移性, 虽然单纯的对抗样本迁移成功率较低, 但可以通过一些技术来提高迁移成功率, 从而在被攻击网络是黑盒的情况下也具有较高的攻击成功率. 而 [1] 则使用基于决策边界的方法来攻击黑盒神经网络. 而对应地, 如 [18], [12] 及其他许多工作则提出了防御对抗攻击的方法.

2.3 神经网络相似性

衡量不同初始化的神经网络相似性是机器学习的重要问题. 我们关心的问题是, 是否相同结构但具有不同初始化的网络, 会最终收敛到几乎" 等价" 的权重, 这对神经网络的可解释性具有重要意义. 该问题的难点在于, 几乎" 等价" 并不代表权重的每个元素都几乎相等, 我们需要更好的度量方式.

[9] 首次尝试解决这一问题. 他们从实验的角度, 使用了包括线性变换下的对应、图匹配等方式度量每层卷积层输出的相似度, 得出了浅层卷积层相似, 深层卷积层不相似的结论. 随后, [16] 则通过理论推导, 设计了每一层的 activation vector 构成的子空间线性相似性, 得出了不同初始化的网络在该度量下不等价的结论. 2019 年, 综述论文 [6] 系统地总结了度量两个神经网络对应层相似度的方法.

3 目标

我们希望探究在不同初始化下的神经网络的区别。具体而言，我们实现了用于学习图像特征的 ResNet 网络 [5]，它在 2015 年由何凯明提出，该网络在图像分类、定位、检测等领域都有优秀的表现。我们使用随机初始化获得了五个不同的 ResNet, 并出于计算能力的限制，在 cifar10 数据集 [7] 上分别进行独立的训练。我们的结果如下：

	ResNet 1	ResNet 2	ResNet 3	ResNet 4	ResNet 5
准确率	94.15%	94.36%	94.06%	94.37%	94.63%

4 迁移学习

对于同一类型且初始化方法相同的网络，它们在同一类任务的表现一般基本相差不大，因为它们都针对这一任务优化了自己的表征形式。我们也就难以根据在原任务的性能判断网络表征是否不同。鉴于此，我们尝试将已经训练完成的网络迁移到其他数据集上测，评估网络在新数据集上的分类性能，试图从中发掘这些网络在实际使用上有无不同。我们认为，如果在各类实际场景中这些网络性能差距不大，那么它们的表征具有基本相同的语义。或者说，在一个我们会真正使用的定义域上，它们的表征并无本质不同。

我们训练使用的数据集为 Cifar10, 测试时，我们专门选择了两个数据集，试图从两个维度理解神经网络的表征区别。

其一是 Cifar100 数据集 [7] ，它与 Cifar10 很相似，但 Cifar100 图片数量相同，但类别更多，这意味着神经网络需要学到更细致的知识，且其与 Cifar10 有大量共用数据。我们希望据此发现网络对原数据集的类内特征表达能力是否存在显著差别。

另一个则是 Fashion-MNIST 数据集 [17] 。该数据集的内容基本与服装相关，和 cifar 10 中包含的图片类别有较大区别，我们试图以此分辨这些网络的表征泛化能力是否相同，是否学习到了底层的纹理特征和具有实际语义的部件。

5 对抗攻击与决策边界

如上一节叙述, 我们仍然将不同初始化的神经网络看成一个个黑盒 $f_1, ..., f_n : \mathcal{I} \to \{0, ..., cls-1\}$. 我们知道这些神经网络在测试集数据 $X_1, ..., X_n$ 中取得了较高的正确率, 这仅仅说明 $f_1, ..., f_n$ 在 $X_1, ..., X_n$ 这些**孤立点**上的表现是相似的, 然而我们知道, 如果对 $X_1, ..., X_n$ 上加入微小的扰动 $\vec{\epsilon}$, 对应的图片仍然是**肉眼可辨认的**, 而 [4] 说明, 加入微小的扰动, 可能对神经网络的预测结果产生巨大的影响. 记肉眼可辨认的图像空间为 $\mathcal{I}$, 如果用测试集数据 $X_1, ..., X_n$ 的**邻域空间** δ[1]代表 $\mathcal{I}$, 我们希望探究, 在邻域空间内, 神经网络是否仍然表现地相似.

我们想法的关键是, 将邻域空间 $\delta(X_i)$ 对应的网络 f 的输出看做一个地图 (如图1所示), 地图中的每一类都构成一个封闭区域: 在该封闭域之内的输入, 对应输出永远是该类. 当然, 其中一个封闭域最为特殊: 包含 $X_i + \vec{0}$ 的这一封闭图形, 我们称之为" **中心域**". 于是, 我们的基本想法是, 探究不同网络对应的" 中心域" 的边界轮廓是否相似, 以及中心域的邻居区域所属类是否相同.

我们希望从两个角度去进行探究: 在对抗样本上的分类相似性, 以及更进一步地, 沿某方向到达分类边界的距离相似度, 来刻画两个网络决策轮廓的相似性. 下文中, 我们会关注两个概念: " 局部相似性" 和" 全局相似性".

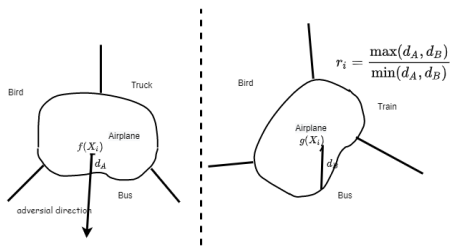

图 1: 如图, 该部分实验我们的基本思路是研究不同网络决策边界的局部和全局相似度, 我们采取一系列方法来刻画不同网络决策边界的性质

5.1 对抗相似度

我们研究两个网络在对抗样本上的表现情况. 本质上, 对抗样本相似性本质上反映了两个网络邻域空间的**局部**相似性, 如果两个网络在对抗样本上的表现差异较大, 也即一个分对在中心域内, 一个分错不再中心域内, 说明二者在某些局部不具有相似性.

在第一组实验中, 我们首先探究使用不同的对抗样本生成方法攻击其中一个网络 f_i, 比较被攻击 (targeted network) 网络和另一个网络 (untargeted network) 的正确率, 以及预测的标签相同的比例. 我们探究了三种不同的攻击方法, 式 (1) 为迭代版本的 FGSM[4], 式 (2) 为直接使用梯度方向的方法:

$$\vec{\epsilon} \leftarrow \alpha * \mathrm{norm}(\vec{\epsilon} + \beta * \mathrm{sgn}(\nabla_{x+\vec{\epsilon}} \mathcal{L}(\theta, x + \vec{\epsilon}, y))) \tag{1}$$

[1]定义图片 X_i 的邻域空间为 $\delta(X_i) = \{X_i + \vec{\epsilon} | ||\epsilon||_2 < threshold\}$

$$\vec{\epsilon} \leftarrow \alpha * \mathrm{norm}(\vec{\epsilon} + \beta\, \mathrm{norm}(\nabla_{x+\vec{\epsilon}} \mathcal{L}(\theta, x+\vec{\epsilon}, y))) \tag{2}$$

其中 α 约束了扰动向量的模长, $norm(x) = \frac{x}{||x||_2}$ 代表模长归一化.

这前两种攻击方法为每张图片单独生成扰动向量，主要关注两个网络的局部特征。为了从更宏观的角度分析两个网络的异同，我们考虑第三种攻击方法——Universal Perturbation[13]。这种攻击只生成一个全局的扰动向量，具有 image-agnostic 的性质。设数据分布为 μ，受到攻击的分类器为 f，Universal Perturbation 的目标是找到扰动向量 v，使得

1. $||v||_p \leq \xi$
2. $P_{x\sim\mu}(f(x+v) \neq f(x)) \geq 1-\delta$

其中 ξ 控制了扰动向量的模长，δ 控制了 fooling rate（扰动之后预测结果发生变化的概率）

我们的比较对象有两个: 一个是对比两个网络对应的扰动样本的正确率: $\frac{1}{N}\sum I[y_i = f(X_i+\vec{\epsilon_i})]$, 另一个是预测两个网络在扰动样本中预测的标签相同的概率: $\frac{1}{N}\sum I[f(X_i+\vec{\epsilon_i}) = g(X_i+\vec{\epsilon_i})]$.

5.2 到达决策边界的距离相似度与决策可视化

上一节中的方法本质上是间接地通过一个分对一个分错展示出分类边界的不相似性, 我们在这一节中通过更直接的方式度量" 中心域" **决策边界**轮廓的相似性. 直接比较两个高维图形的相似性是困难的, 这里我们转化为: 比较两个网络在相同样本点 X_i 上, 以相同方向扰动, 第一次走出边界的距离是否是接近的? 如果两个神经网络是相似的, 那么得到的两个距离便是接近的.

具体地, 在样本点 X_i 上任给一个方向向量 $\vec{v}: ||\vec{v}||_2 = 1$, 定义第一次走出边界的距离为 $dis(X_i, \vec{v}, f) = \arg\min_d\{f(X_i + d\vec{v}) \neq y_i\}$. 有了上述定义后, 则

$$r_i = \frac{\max(dis(X_i, \vec{v_i}, f), dis(X_i, \vec{v_i}, g))}{\min(dis(X_i, \vec{v_i}, f), dis(X_i, \vec{v_i}, g))}$$

便反映了两个网络到边界的距离相似性, 从而刻画了决策边界轮廓的相似性. 通过画出 r_i 的累积分布函数, 我们便能直观地看出相似性了. 同样地, 我们还比较两个网络**第一次越过边界**后所在分类相同的概率.

在该部分中, 我们所取的方向向量有两种: 一种是对抗方向 (adversarial direction), 另一种则是随机方向. 对抗方向仍然反映了**局部相似性**, 而随机方向则可以反映**全局相似性**, 即是否决策边界在整体上是不相似的.

最后, 我们可视化了一些样本的决策边界与邻域空间的分类情况, 如图5所示, 作为该部分的补充.

5.3 决策边界的高维几何特征相似度

作为 5.2 节的延伸，我们希望更加全面地研究决策边界的性质。我们发现，Universal Perturbation 能够揭示出决策边界的更多几何特征。

事实上，Universal Perturbation 的存在意味着神经网络在不同数据点周围的决策边界，在几何特征上具有一定相关性，因为只需要一个特定的扰动就可以将大部分数据点推出决策边界。换言之，Universal Perturbation 所在的方向揭示了大多数决策边界的公共的薄弱点，在该方向上数据点和边界的距离较短。相比于同一模长的随机向量，Universal Perturbation 具有特殊的几何意义。根据 [3]，为了扰动某一特定的数据点，随机扰动的模长需要达到 $\Theta(\sqrt{d}||r||_2)$，其中 d 为数据的维数，r 为数据点到决策边界的最短距离。由于我们要求任何的扰动都不能对数据分布产生显著影响，Universal Perturbation 的模长往往要比上述随机扰动的模长低一个数量级 [13]。在实验环节中，我们也比较了随机扰动和 Universal Perturbation 的 fooling rate 的实际差别。

以上结果说明，存在一个包含 Universal Perturbation 的低维子空间（大多数随机向量都不位于该空间），而其中的扰动向量几乎能无差别地影响所有数据点的决策。具体而言，[13] 对训练集的数据点分别生成对抗样本，组合成一个矩阵并进行 SVD 分解，发现奇异值的下降速度很快，证实了子空间的维度是较低的。我们认为，低维子空间的存在能够从全局角度反映出决策边界的冗余。

总而言之，Universal Perturbation 具有如下性质：

1. 能够在数据集上进行泛化的攻击，反映了决策边界的全局特征
2. 相比于同一模长的随机向量具有特殊性，反映了决策边界上公共的薄弱点
3. Universal Perturbation 所在的低维子空间反映了决策边界的冗余

因此，在这一节中我们主要以神经网络在 Universal Perturbation 下的表现作为依据，来衡量不同网络的几何特征相似度。具体而言，我们希望得到决策边界的“等高线”——首先取定 Universal Perturbation 的模长 ξ 作为“高度”，我们在 ξ-球面上随机选择一个方向生成扰动向量，并分别计算这些扰动的 fooling rate；如果 fooling rate 达到了和 Universal Perturbation 相近的水平，我们认为该扰动触碰到了决策边界，从而得到了决策边界在该方向上的“高度”；反之，如果 fooling rate 较低，说明该扰动没有触碰到决策边界，决策边界在该方向上的“高度”要大于当前模长。需要注意的是，本节中随机方向的选取和 5.2 节的随机扰动有所不同，需要满足额外的约束：与 Universal Perturbation 呈特定夹角。由于高维空间的性质，如果完全随机地在单位球上选取两个方向，有很大概率这两个方向是近似垂直的 (nearly orthogonal)，即这两个向量的内积为 $O(\frac{1}{\sqrt{d}})$，其中 d 为单位球的维度[2]。

[2]有如下定理：对于 $c \geq 1$ 以及 $d \geq 3$，d 维单位球中的向量至少有 $1 - \frac{2}{c}e^{-c^2/2}$ 的比例满足 $|x_1| \leq \frac{c}{\sqrt{d-1}}$，其中 $|x_1|$ 为向量在第一个坐标轴上的分量。事实上，我们可以将任意一个单位球上的向量作为第一个坐标轴。这一定理来自于 John Hopcroft 教授的“信息科学中的数学”课程，教材为 Foundations of Data Science

因此，如果将 Universal Perturbation 作为北极，完全随机选取的扰动基本集中于赤道平面附近，缺乏对北极点邻域的刻画。因此，我们在一定范围内选取随机扰动和 Universal Perturbation 之间的夹角，然后在这一夹角所确定的圆锥上生成扰动。可以预见，随着夹角的增大，随机扰动和 Universal Perturbation 之间的 fooling rate 差距将越来越大；给定这一差距的上限 (e.g. 5%)，我们可以将满足上限的夹角范围视为子空间维度一种度量（从而也体现了决策边界的冗余程度）。

综上所述，通过比较 targeted network 和 untargeted network 的表现，我们能比较两个网络的决策边界在 Universal Perturbation 所在方向上的特异性，以及二者冗余程度的差别。

6 实验

6.1 迁移实验

6.1.1 实验设定

出于计算能力考虑，我们在 cifar 10 数据集进行预训练。我们运用相同的初始化方法，预训练了五个不同的初始权值的 Resnet 18 网络，这五个网络在 cifar 10 上分别可以达到 94.15%，94.36%，94.06%，94.37%，94.63% 的准确率。也符合我们认为的在原任务上不同初始值的网络[3]性能差异不大的认知。之后我们将这些网络迁移到了 cifar 100 和 Fashion MNIST 数据集上并进行了微调。具体来说，对于所有网络，我们首先替换掉了最后的全连接层以适应目标训练集，同时我们固定了其他参数。之后我们选取了 batch_size 为 128，学习率为 0.1，让每个网络都在目标数据集上训练了 *num_epochs* 轮（cifar 100 中为 15，Fashion-MNIST 中为 40）以优化最后全连接层对之前提取到的特征的组合能力。最后测试了它们在目标测试集上的分类效果。

6.1.2 实验分析

	Net1	Net2	Net3	Net4	Net5	正确率最大差值
cifar 100	0.2245	0.2283	0.2236	0.2365	0.2322	0.0129
Fashion-MNIST	0.6359	0.6374	0.6239	0.5972	0.6187	0.0384

表 1: 五个网络在两个数据集上的准确率

从如上图表1中，我们可以看到，在 cifar 100 数据集上，五个网络准确率都很低，我们认为这说明这些网络得到的表征基本只能用于将图片分成 cifar10 中的十个类别，这些特征基本不能再将图片分为更小的子类，也就是它们的类内区别能力不强。不过这也比较符合我们对神经网络的认知，因为训练时我们并没有要求网络做到这一点。但这些网络在将图片分为一百个类别时，还是显现了大约 1.2% 的差异，说明网络还是稍有不同的。

[3]这里及以下都是指网络结构和初始化方法相同但具体的初始值不同的网络

而对 Fashion-MNIST 的结果也从可迁移能力上说明了这一点。可以看到，虽然 cifar 10 与 Fashion-MNIST 相差甚远——一个是彩色图片一个是黑白照片，一个以自然事物为主另一个围绕服装展开，但迁移后仍然具备一定的区分能力。然而，它们的迁移能力却有着较大的不同，最好和最差的准确率差异达到了约 3.8%，可以说这些网络的表征存在一定差异，从而导致了它们的准确率在迁移后出现分化。

6.2 对抗攻击与决策边界实验

6.2.1 实验设定

我们在 CIFAR 10 上进行这一节的实验. 使用 ResNet18 框架训练了 5 个网络, 其在测试集上的原始准确率均为 $\sim 94\%$. 对于对抗相似性的实验, 我们严格控制扰动的模长, 使得扰动模长为整张图片期望模长的某一比例. 这里, 若图片为 32*32*3, 每个像素方差归一化的话, 我们认为整张图片的期望模长为 $L = 32\sqrt{3}$. 我们只考虑肉眼可识别的图片, 因此设定 $threshold = 0.5L$, 在 5.2 的实验里, 我们简单丢弃距离超过该阈值的方向. 图2展示了不同扰动模长下的图片.

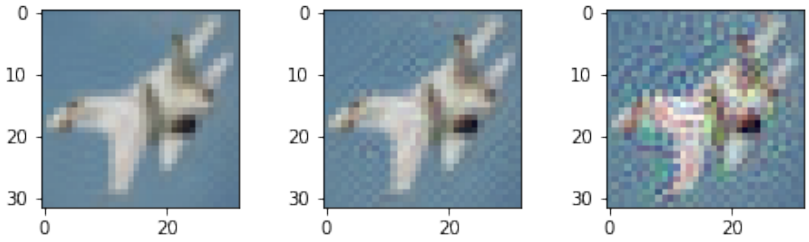

(a) $\epsilon = 0.05L$ (b) $\epsilon = 0.2L$ (c) $\epsilon = 0.5L$

图 2: 不同扰动下的图片可视化

6.2.2 实验结果

图3展示了 5.1 节关于对抗相似性的实验结果. 我们认为, 如果两个网络完全相同, 则二者在对抗样本上的成功率将会是相似的, 并且分错的样本预测的标签也完全相同; 差距越大, 说明两个神经网络越具有大的差异.

我们发现, 实验结果的红蓝曲线存在一定的间隙, 此外, 当 $\epsilon = 0.05L$ 时, 两个网络预测到相同标签的概率 $< 50\%$. 这说明在对抗样本上, 不同初始化的网络具有一定的不相似性. 我们还发现, 当扰动进一步增大时, 橙色曲线有增长的趋势. 我们对此的解释是, 此时扰动带来的属于另一类别的纹理特征变得更加明显, 该特征对于人类不可理解, 但神经网络可以理解, 且对于相同结构的神经网络具有一定的" 通用性". 于是, 当扰动较明显时, 作用于网络 A 的对抗扰动对 B 也会起作用. 这一现象, 连同蓝色线 (未被攻击网络在对抗扰动的正确率) 在绿色线 (未被攻击网络在随机扰动的正确率) 以下, 反映了一种**介于完全无关和几乎完全一致的弱相似性**。

比较 FGSM、FGDM 和 Universal Perturbation，我们发现后者的红蓝曲线差距始终更小，这说明在全局意义下，两个网络是具有一定相似度的。相比于黑色和绿色曲线对应的随机扰动，我们发现 Universal Perturbation 的确符合 5.3 的分析——Universal Perturbation 所在的方向具有特殊的几何意义。

在生成 Universal Perturbation 的过程中，我们仅使用了 1k 个数据点，并在这些数据点上要求达到 90% 的 fooling rate；而应用到整个测试集（大小为 10k）后，仍然可以达到 80% 以上的 fooling rate(对应扰动的模长为 $0.2L$)。Universal Perturbation 在数据集上泛化能力足以说明其反映的是一种稳定的全局特征，因此 5.3 节基于 Universal Perturbation 的比较是有意义的。

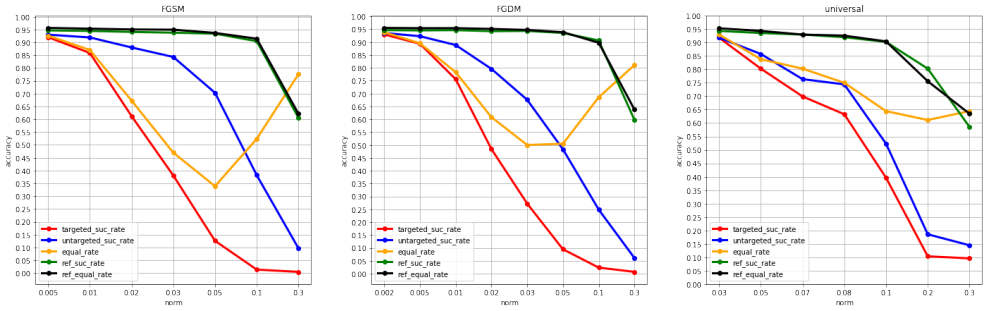

(a) Fast Gradient Sign Method (b) Fast Gradient Direction Method (c) Universal

图 3: 对抗相似性的实验结果. 红蓝两条线代表被攻击网络/未被针对的网络分类成功率随模长的变化, 橙色的线代表两个网络预测标签相同的概率, 绿黑两条线则代表随机选取两个扰动 v_1, v_2 分别作用于两个网络, 其分类成功率和预测标签相同概率, 这两条线作为参照.

图4图5和表2表3展示了 5.2 节的实验结果. 我们使用累积分布函数 cdf 可视化结果. 为了衡量这一分布曲线的意义, 我们使用如下参照: 设 $\mathcal{D}_1, \mathcal{D}_2$ 代表两个网络 f_1, f_2 在随机方向时距离类边界的距离分布, $X_1 \sim \mathcal{D}_1, X_2 \sim \mathcal{D}_2$, 那么 $\frac{\max(X_1,X_2)}{\min(X_1,X_2)}$ 就刻画了两个网络分布轮廓完全不相关, 只是单纯从分布中随机取两个数的比值分布. 该分布曲线是重要的参照[4], 实验组相比于参照组越上凸, 说明两个网络的决策轮廓越相似.

先来看对抗方向下的结果. 这一情形, 被攻击网络和另一个网络的距离差距非常大: 例如, 有 50% 概率使得到达边界的距离的比值超过 2, 有 10% 的概率距离的比值超过 10. 这是对上一个实验结果的补充: 它表明, 在对抗方向这种局部方向上, 不同神经网络的决策边界轮廓具有较大的差异. 同样地, 表3说明, 对于不同网络, 其对抗方向上的紧邻区域对应的类别也有较大概率是不同的.

再来看随机方向下的结果. 蓝色的实验组曲线比橙色的参照曲线要更凸, 说明在多数情况下, 两个网络在某个样本和方向下到达决策边界的距离是接近的, 这表明了决策边界相比于完全不一致而言的一种相似性; 然而, 这种相似性还远远没达到**几乎完全一致**的

[4]简单地讲, 该参照就是 5.2 所述比值的分布去掉" 两个网络扰动方向相同" 这一约束. 该参照衡量了数据点 X_i 到边界距离的整体分布情况, 整体分布越集中, 则该参照越上凸; 实验组之于参照组越凸, 则网络越相似

	Net1	Net2	Net3	Net4	Net5
Net1	/	0.608	0.602	0.632	0.637
Net2	/	/	0.655	0.590	0.633
Net3	/	/	/	0.615	0.642
Net4	/	/	/	/	0.636
Net5	/	/	/	/	/

表 2: 随机方向下, 两个网络" 中心域" 相邻区域类别相等的概率. 这表明了一种比完全随机要强, 但比网络几乎完全一致要弱的相关性

	Net1	Net2	Net3	Net4	Net5
Net1	/	0.480	0.477	0.488	0.484
Net2	/	/	0.445	0.457	0.468
Net3	/	/	/	0.474	0.504
Net4	/	/	/	/	0.456
Net5	/	/	/	/	/

表 3: 对抗方向下, 两个网络" 中心域" 相邻区域类别相等的概率

程度. 例如在图4(a) 中, 仍有 10% 的概率, 距离的比值超过 2; 表2说明, " 中心域" 周边的相邻区域, 其所属类别也有相当的概率是不同的.

总的说来, 我们的实验表明, 在某些局部, 决策轮廓具有很强的不相关性; 而从整体上而言, 决策边界具有一定的弱相关性.

除此之外, 图5还展示了一些样本邻域所属类别的可视化结果对比, 结果依然符合上面的结论.

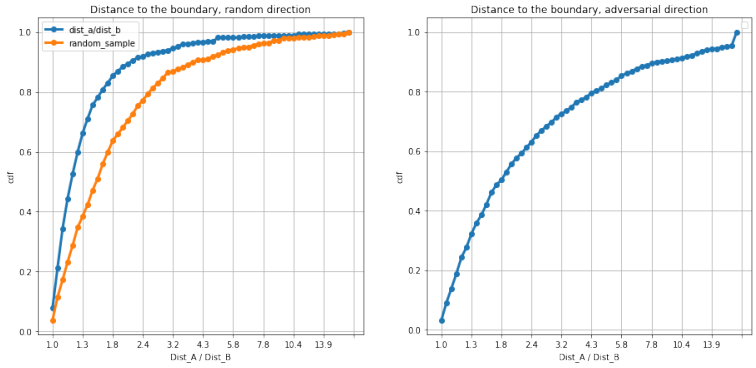

(a) Random direction (b) Adversarial direction

图 4: 不同网络到达决策边界距离的比较. 我们刻画两个距离比值的 cdf 曲线, 也即累积分布函数, 作为参照 (橙色), 我们还给出在放掉方向一致的约束, 从距离分布 $\mathcal{D}_1, \mathcal{D}_2$ 中随机抽取两个值, 其对应比值的分布是怎样的. (a): 使用随机方向; (b): 使用对抗方向

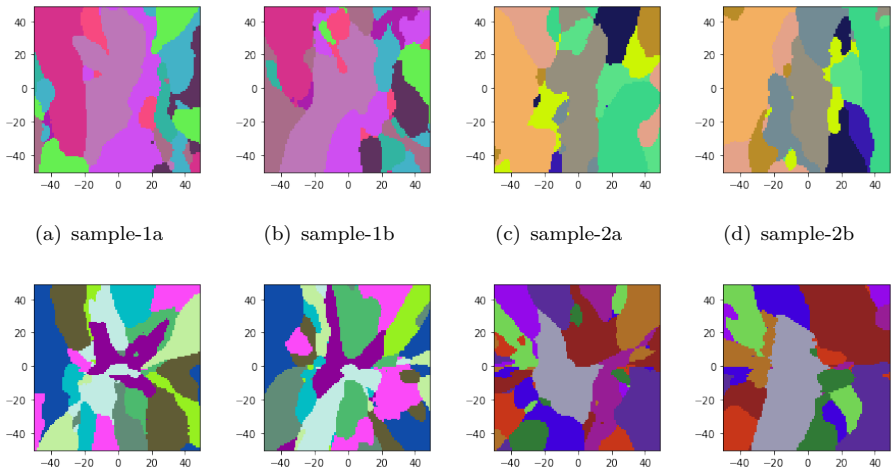

(a) sample-1a (b) sample-1b (c) sample-2a (d) sample-2b

(e) sample-1a-adv (f) sample-1b-adv (g) sample-2a-adv (h) sample-2b-adv

图 5: 决策边界的可视化结果. 上面 4 张图展示了选取两个随机正交方向作为对图片的扰动方向, 分别变化两个方向扰动长度 (每像素单位为 $0.01L$) 后两个网络对应输出类别的图片, 下面 4 张图则为 y 轴是对抗方向, x 轴为随机方向的结果. 可以看出每个类对应的封闭区域在两个网络之间有明显差异, 但依旧存在某种程度的弱相关性.

图6展示了 5.3 节的实验结果.

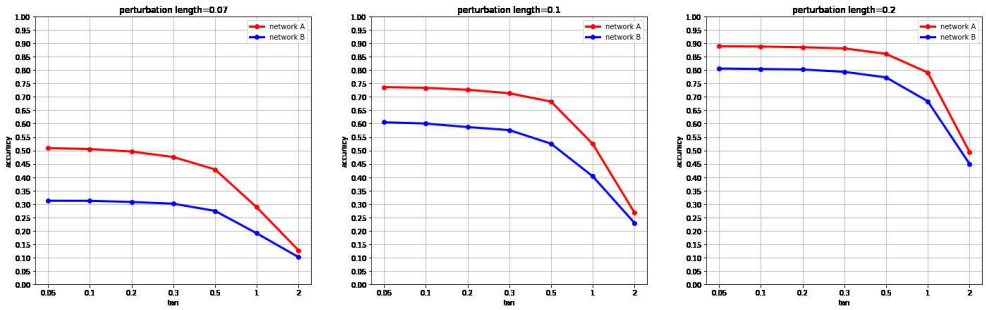

(a) norm=0.07L (b) norm=0.1L (c) norm=0.2L

图 6: 不同网络决策边界的几何特征 (5.3 节). 固定扰动的模长，我们在和 Universal Perturbation 呈不同夹角的方向上选取随机扰动。每张图中的红蓝两条线分别代表 targeted network/untargeted network 的 fooling rate 随夹角正切值的变化。其中最大夹角为 $arctan(2) \approx 63°$

实验发现，在 Universal Perturbation 附近 $0 \sim 22.5°$（tan 值为 0~0.5）的夹角范围内存在一个关键的邻域 (记为 δ)，具有如下两条性质：

1. targeted network 和 untargeted network 之间 fooling rate 的差值基本上保持恒定

2. 该邻域内，对于任意一个网络来说，随机扰动的表现基本与 Universal Perturbation 一致（fooling rate 差距不超过 5%）

我们接下来逐一地分析这两条性质。

性质 1：不同初始化的网络，其决策边界是有一定差异的。然而，该差异主要在 Universal Perturbation 的 δ 邻域内得到体现。随着角度的增大，targeted network 和 untargeted network 之间 fooling rate 越来越接近，差异逐渐消失。

性质 2：由于随机扰动的表现基本与 Universal Perturbation 一致，根据 5.3 节的分析，我们可以将 δ 邻域视为 Universal Perturbation 所在子空间维度一种度量（从而也体现了决策边界的冗余程度）。我们看到，该子空间的维度的确是较低的，因为对于高维空间来说 (5.3 节)，夹角为 22.5° 所确定的球冠在整个球面中所占比例非常小。同时，由于红蓝曲线呈现出非常相似的变化趋势——对两个网络而言，随机扰动与 Universal Perturbation 在相同的 δ 邻域内表现出一致性，我们可以认为，两个网络的决策边界的冗余是类似的。

7 结论

在这篇工作中, 我们研究了具有相同结构不同初始化的神经网络的相似度. 我们将神经网络看成黑盒, 通过神经网络在迁移学习和对抗样本两个下游任务下的表现相似性来研究神经网络相似性. 此外, 我们还通过探索决策边界的相似程度探究网络相似性. 通过大量的实验我们发现, 在迁移学习任务下, 神经网络具有一定程度的相关性; 在对抗样本任务下, 神经网络差异性较大, 但仍有一定的弱相关性; 对于决策边界, 神经网络在对抗方向差异较大, 在随机方向具有一定的弱相关性. 至此我们得出结论, 不同初始化的网络在整体上具有弱一致性, 但在局部有较大的差异.

Appendix

我们训练使用的数据集为 Cifar10, 包含 60000 张 32×32 彩色图片，分为“飞机、轿车、鸟、猫、鹿、狗、青蛙、马、船、卡车”十类，每类包含 6000 张图片。我们使用其中的 50000 张作为训练集，另外 10000 张作为测试集。其部分数据如图 6 所示。

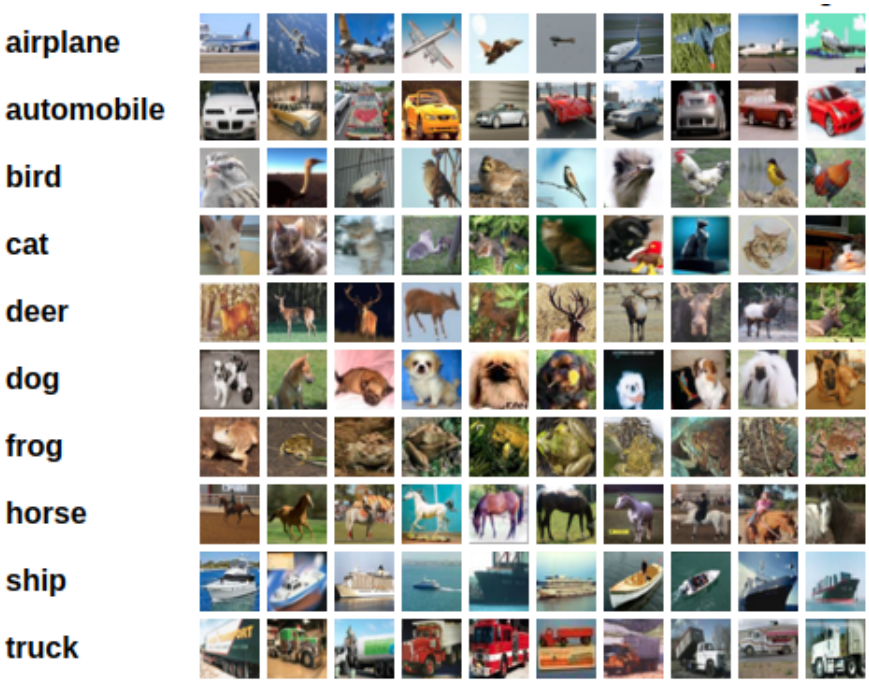

图 7: Cifar10 的部分数据

Cifar100 数据集，它与 Cifar10 很相似，但 Cifar100 包含 20 个超类，每个超类又细分为 5 个小类，每个小类共 600 张图片。与 Cifar10 相比较，Cifar100 图片数量相同，但类别更多，这意味着神经网络需要学到更细致的知识。图 7 显示了 Cifar100 的具体分类，它与 Cifar10 有大量的共用数据。

Fashion-MNIST 数据集有 60000 张训练图片和 10000 张测试图片，为 28×28 黑白图片，分为“T 恤、裤子、套头衫、裙子、外套、凉鞋、衬衫、运动鞋、包、靴子”十类。比起常用的 MNIST，该数据集的特征更加复杂，更加困难。

Superclass	Classes
aquatic mammals	beaver, dolphin, otter, seal, whale
fish	aquarium fish, flatfish, ray, shark, trout
flowers	orchids, poppies, roses, sunflowers, tulips
food containers	bottles, bowls, cans, cups, plates
fruit and vegetables	apples, mushrooms, oranges, pears, sweet peppers
household electrical devices	clock, computer keyboard, lamp, telephone, television
household furniture	bed, chair, couch, table, wardrobe
insects	bee, beetle, butterfly, caterpillar, cockroach
large carnivores	bear, leopard, lion, tiger, wolf
large man-made outdoor things	bridge, castle, house, road, skyscraper
large natural outdoor scenes	cloud, forest, mountain, plain, sea
large omnivores and herbivores	camel, cattle, chimpanzee, elephant, kangaroo
medium-sized mammals	fox, porcupine, possum, raccoon, skunk
non-insect invertebrates	crab, lobster, snail, spider, worm
people	baby, boy, girl, man, woman
reptiles	crocodile, dinosaur, lizard, snake, turtle
small mammals	hamster, mouse, rabbit, shrew, squirrel
trees	maple, oak, palm, pine, willow
vehicles 1	bicycle, bus, motorcycle, pickup truck, train
vehicles 2	lawn-mower, rocket, streetcar, tank, tractor

图 8: Cifar100 的分类情况

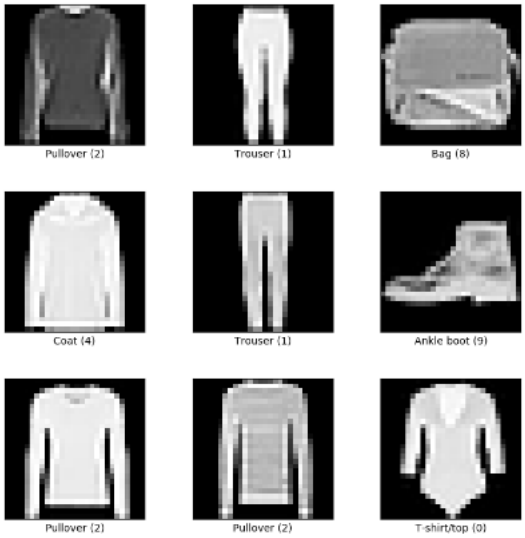

图 9: FMNIST 的部分数据

References

[1] Wieland Brendel, Jonas Rauber, and Matthias Bethge. Decision-based adversarial attacks: Reliable attacks against black-box machine learning models. In *6th International Conference on Learning Representations, ICLR 2018, Vancouver, BC, Canada, April 30 - May 3, 2018, Conference Track Proceedings*. OpenReview.net, 2018.

[2] Wenyuan Dai, Qiang Yang, Gui-Rong Xue, and Yong Yu. Boosting for transfer learning. In *Proceedings of the 24th international conference on Machine learning*, pages 193–200, 2007.

[3] Alhussein Fawzi, Seyed-Mohsen Moosavi-Dezfooli, and Pascal Frossard. Robustness of classifiers: from adversarial to random noise, 2016.

[4] Ian Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples. In *International Conference on Learning Representations*, 2015.

[5] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.

[6] Simon Kornblith, Mohammad Norouzi, Honglak Lee, and Geoffrey E. Hinton. Similarity of neural network representations revisited. In *Proceedings of the 36th International Conference on Machine Learning, ICML 2019, 9-15 June 2019, Long Beach, California, USA*, volume 97 of *Proceedings of Machine Learning Research*, pages 3519–3529. PMLR, 2019.

[7] Alex Krizhevsky, Geoffrey Hinton, et al. Learning multiple layers of features from tiny images. 2009.

[8] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in neural information processing systems*, pages 1097–1105, 2012.

[9] Yixuan Li, Jason Yosinski, Jeff Clune, Hod Lipson, and John E. Hopcroft. Convergent learning: Do different neural networks learn the same representations? In *4th International Conference on Learning Representations, ICLR 2016, San Juan, Puerto Rico, May 2-4, 2016, Conference Track Proceedings*, 2016.

[10] Yanpei Liu, Xinyun Chen, Chang Liu, and Dawn Song. Delving into transferable adversarial examples and black-box attacks. In *5th International Conference on Learning Representations, ICLR 2017, Toulon, France, April 24-26, 2017, Conference Track Proceedings*. OpenReview.net, 2017.

[11] Mingsheng Long, Han Zhu, Jianmin Wang, and Michael I Jordan. Deep transfer learning with joint adaptation networks. In *Proceedings of the 34th International Conference on Machine Learning-Volume 70*, pages 2208–2217. JMLR. org, 2017.

[12] Dongyu Meng and Hao Chen. Magnet: a two-pronged defense against adversarial examples. *CoRR*, abs/1705.09064, 2017.

[13] Seyed-Mohsen Moosavi-Dezfooli, Alhussein Fawzi, Omar Fawzi, and Pascal Frossard. Universal adversarial perturbations. In *The IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, July 2017.

[14] Sinno Jialin Pan and Qiang Yang. A survey on transfer learning. *IEEE Transactions on knowledge and data engineering*, 22(10):1345–1359, 2009.

[15] Lorien Y Pratt. Discriminability-based transfer between neural networks. In *Advances in neural information processing systems*, pages 204–211, 1993.

[16] Liwei Wang, Lunjia Hu, Jiayuan Gu, Zhiqiang Hu, Yue Wu, Kun He, and John E. Hopcroft. Towards understanding learning representations: To what extent do different neural networks learn the same representation. In *Advances in Neural Information Processing Systems 31: Annual Conference on Neural Information Processing Systems 2018, NeurIPS 2018, 3-8 December 2018, Montréal, Canada*, pages 9607–9616, 2018.

[17] Han Xiao, Kashif Rasul, and Roland Vollgraf. Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms. *arXiv preprint arXiv:1708.07747*, 2017.

[18] Cihang Xie, Jianyu Wang, Zhishuai Zhang, Zhou Ren, and Alan L. Yuille. Mitigating adversarial effects through randomization. *CoRR*, abs/1711.01991, 2017.